

## Musterlösung: Längsschnittanalysen und Veränderungsmessung I

### Aufgabe 1 (Variabilitätsmodell)

Als Vorbereitung müssen das `lme4`-Paket und der `affect`-Datensatz geladen werden.

```
# setwd("myworkindirectory")
load("affect.rda")
library(lme4)
```

Überprüfen Sie mit einer ANOVA die statistische Bedeutsamkeit der Clusterung für die gute vs. schlechte Stimmung (Variable `gut`):

```
anova(lm(gut ~ ID, affect))
```

Analysis of Variance Table

Response: gut

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
ID	72	471.64	6.5505	9.2747	< 2.2e-16
Residuals	724	511.35	0.7063		

Schätzen Sie das entsprechende Nullmodell mit der `lmer()`-Funktion:

```
null <- lmer(gut ~ 1 + (1 | ID), affect)
summary(null)
```

Linear mixed model fit by REML ['lmerMod']

Formula: gut ~ 1 + (1 | ID)

Data: affect

REML criterion at convergence: 2152.5

Scaled residuals:

	Min	1Q	Median	3Q	Max
	-3.5945	-0.3964	0.1647	0.5237	3.1403

Random effects:

Groups	Name	Variance	Std.Dev.
ID	(Intercept)	0.5642	0.7511

```
Residual          0.7068    0.8407
Number of obs: 797, groups: ID, 73
```

Fixed effects:

```
          Estimate Std. Error t value
(Intercept) 4.93391    0.09292    53.1
```

Berechnen Sie die ICC aus den Varianzkomponenten:

```
var.u0i <- unlist(VarCorr(null))
var.rti <- sigma(null)^2
var.u0i / (var.u0i + var.rti)
```

```
ID
0.4438969
```

## Aufgabe 2 (Growth Curve Mehrebenenmodell)

Erstellen Sie ein Modell, in dem gute Stimmung linear von der Tageszeit vorhergesagt wird. Das Ausgangsniveau der Stimmung darf dabei über Personen variieren. Gibt es einen (von Null verschiedenen) mittleren linearen Trend der guten Stimmung über alle Personen hinweg?

```
line <- lmer(gut ~ 1 + time + (1 | ID), affect)
summary(line)
```

```
Linear mixed model fit by REML ['lmerMod']
Formula: gut ~ 1 + time + (1 | ID)
Data: affect
```

REML criterion at convergence: 2145.6

Scaled residuals:

```
      Min       1Q   Median       3Q      Max
-3.4190 -0.3941  0.1414  0.5482  3.1185
```

Random effects:

```
Groups   Name             Variance Std.Dev.
ID       (Intercept) 0.5670    0.7530
Residual                0.6935    0.8328
```

Number of obs: 797, groups: ID, 73

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	4.748403	0.104844	45.290
time	0.032136	0.008374	3.838

Correlation of Fixed Effects:

	(Intr)
time	-0.461

Linearer Trend von Null verschieden?

```
test <- lmerTest::lmer(gut ~ 1 + time + (1 | ID), affect)
summary(test)$coef
```

	Estimate	Std. Error	df	t value	Pr(> t )
(Intercept)	4.74840323	0.104844370	113.4268	45.290016	1.795806e-74
time	0.03213646	0.008374306	725.3395	3.837507	1.351244e-04

```
confint(line, method = "boot", n = 1000)
```

	2.5 %	97.5 %
.sig01	0.60488557	0.8918273
.sigma	0.79170062	0.8794689
(Intercept)	4.54078952	4.9573825
time	0.01542015	0.0488411

Ja,  $t(725.3) = 3.838$ ,  $p < 0.05$ . 95% CI von time überdeckt nicht die Null (CI-Grenzen können bei Ihnen aufgrund des Zufallsprozesses leicht abweichen).

Erweitern Sie das lineare Modell für die gute Stimmung, um zu untersuchen, ob Varianz in den linearen Steigungskoeffizienten vorhanden ist.

```
line_rs <- lmer(gut ~ 1 + time + (1 + time | ID), affect)
summary(line_rs)
```

Linear mixed model fit by REML ['lmerMod']

Formula: gut ~ 1 + time + (1 + time | ID)

Data: affect

REML criterion at convergence: 2104.1

Scaled residuals:

Min	1Q	Median	3Q	Max
-3.4596	-0.4006	0.1561	0.5281	3.0919

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
ID	(Intercept)	1.075418	1.03702	
	time	0.007061	0.08403	-0.73
Residual		0.600454	0.77489	

Number of obs: 797, groups: ID, 73

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	4.74503	0.13274	35.747
time	0.03244	0.01261	2.572

Correlation of Fixed Effects:

	(Intr)
time	-0.737

```
confint(line_rs, method = "boot", n = 1000)
```

	2.5 %	97.5 %
.sig01	0.831494081	1.23101902
.sig02	-0.856989784	-0.54569231
.sig03	0.061484880	0.10516362
.sigma	0.734729686	0.81779379
(Intercept)	4.503874961	5.00459077
time	0.007147791	0.05759711

```
anova(line_rs, line, refit = FALSE)
```

Data: affect

Models:

line: gut ~ 1 + time + (1 | ID)

line\_rs: gut ~ 1 + time + (1 + time | ID)

npair	AIC	BIC	logLik	deviance	Chisq	Df	Pr(>Chisq)
-------	-----	-----	--------	----------	-------	----	------------

```
line      4 2153.6 2172.4 -1072.8  2145.6
line_rs   6 2116.1 2144.2 -1052.0  2104.1 41.539  2  9.55e-10
```

Ja, die Standardabweichung der random slope beträgt 0.08403 mit einem CI welches nicht die Null überdeckt (Grenzen können leicht variieren). Der LRT zeigt an, dass das restriktivere Modell (ohne random slopes) signifikant schlechter auf die Daten passt als das Modell mit random slopes.

Wie sind die random effects miteinander korreliert? Was bedeutet diese Korrelation inhaltlich?

```
summary(line_rs)$var
```

Groups	Name	Std.Dev.	Corr
ID	(Intercept)	1.037024	
	time	0.084032	-0.731
Residual		0.774890	

Korrelation von -0.73 -> Höhere Intercepts gehen mit niedrigeren Steigungen einher

### Aufgabe 3 (Latent Growth Curve Modell)

Betrachten Sie nochmals die Übungsaufgaben zur Sitzung 13 SEM des Wintersemesters. Laden Sie den Datensatz `stimmung.rda` (Achtung: Objektname auch `affect` so wie bei dem anderen Datensatz).

```
load("stimmung.rda")
```

```
str(affect)
```

```
'data.frame':  249 obs. of  14 variables:
 $ SW1_1  : int  2 0 2 9 1 0 4 0 2 4 ...
 $ SW2_1  : int  4 5 1 0 1 5 3 0 2 8 ...
 $ SW3_1  : int  4 6 7 0 1 4 6 0 2 6 ...
 $ SW4_1  : int  4 0 2 0 2 0 3 0 2 0 ...
 $ stim1_1: int  4 0 3 1 0 2 2 0 2 3 ...
 $ stim6_1: int  5 0 4 4 2 0 3 0 1 4 ...
 $ stim2_1: int  3 0 2 0 4 3 1 0 1 3 ...
 $ stim5_1: int  3 0 4 0 3 2 1 0 1 3 ...
 $ stim1_2: int  2 3 3 2 0 2 2 0 1 2 ...
```

```
$ stim6_2: int 6 3 3 2 0 3 2 0 2 4 ...
$ stim1_3: int 4 3 4 1 0 2 2 1 2 3 ...
$ stim6_3: int 4 3 2 0 0 2 2 2 2 4 ...
$ stim1_4: int 3 0 3 2 1 3 2 1 2 4 ...
$ stim6_4: int 4 0 2 2 0 3 2 2 2 4 ...
```

Spezifizieren Sie ein Single-Indicator Latent Growth Curve Modell für die Stimmungsvariablen stim1. Lassen Sie die Erwartungswerte des Intercept und des Slope Faktors frei schätzen und setzen Sie alle Intercepts der Items auf Null.

```
lgc1 <- "
Int =~ 1*stim1_1 + 1*stim1_2 + 1*stim1_3 + 1*stim1_4
Slo =~ 0*stim1_1 + 1*stim1_2 + 2*stim1_3 + 3*stim1_4

Int ~ NA*1
Slo ~ NA*1

stim1_1 ~ 0*1
stim1_2 ~ 0*1
stim1_3 ~ 0*1
stim1_4 ~ 0*1
"

library(lavaan)
lgc_fit1 <- sem(lgc1, data = affect, meanstructure = TRUE)
```

Betrachten Sie den Fit des Modells und interpretieren Sie die Modellergebnisse.

```
fitmeasures(lgc_fit1)[c("chisq", "df", "pvalue", "srmr", "rmsea", "cfi", "tli")]
```

```
      chisq      df    pvalue    srmr    rmsea    cfi    tli
1.2667764 5.0000000 0.9383129 0.0156615 0.0000000 1.0000000 1.0089991
```

```
summary(lgc_fit1, standardize = TRUE)
```

lavaan 0.6.15 ended normally after 28 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	9

Number of observations 249

Model Test User Model:

Test statistic 1.267  
 Degrees of freedom 5  
 P-value (Chi-square) 0.938

Parameter Estimates:

Standard errors Standard  
 Information Expected  
 Information saturated (h1) model Structured

Latent Variables:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
Int =~						
stim1_1	1.000				1.598	0.827
stim1_2	1.000				1.598	0.854
stim1_3	1.000				1.598	0.836
stim1_4	1.000				1.598	0.853
Slo =~						
stim1_1	0.000				0.000	0.000
stim1_2	1.000				0.269	0.144
stim1_3	2.000				0.539	0.282
stim1_4	3.000				0.808	0.431

Covariances:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
Int ~~						
Slo	-0.126	0.083	-1.513	0.130	-0.292	-0.292

Intercepts:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
Int	3.165	0.116	27.219	0.000	1.981	1.981
Slo	0.148	0.035	4.275	0.000	0.549	0.549
.stim1_1	0.000				0.000	0.000
.stim1_2	0.000				0.000	0.000
.stim1_3	0.000				0.000	0.000
.stim1_4	0.000				0.000	0.000

Variances:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stim1_1	1.181	0.198	5.960	0.000	1.181	0.316
.stim1_2	1.126	0.136	8.274	0.000	1.126	0.322
.stim1_3	1.316	0.150	8.747	0.000	1.316	0.360
.stim1_4	1.062	0.194	5.482	0.000	1.062	0.302
Int	2.554	0.317	8.062	0.000	1.000	1.000
Slo	0.073	0.039	1.852	0.064	1.000	1.000

Das Modell passt sehr gut auf die Daten. Zum ersten Zeitpunkt zeigen die Personen eine mittlere Stimmung von 3.165, welche über die Zeit hinweg im Mittel ansteigt (0.148 Einheiten mit jedem Messzeitpunkt (ca. eine Stunde)). Es bestehen inter-individuelle Unterschiede im Ausgangswert (Varianz des Intercept Faktors). Die Varianz des Slope Faktors ist nicht signifikant, sodass inter-individuelle Unterschiede im Wachstum ggf. nicht modelliert werden müssten. Intercept und Slope korrelieren zu -0.292 (ein höherer Ausgangswert geht einher mit geringerem Wachstum), jedoch nicht signifikant. Wir betrachten aufgrund der Ergebnisse noch ein reines Variabilitätsmodell:

Modell ohne Slope: Latent State Trait Modell (single-Indicator)

```
lst1 <- "
Int =~ 1*stim1_1 + 1*stim1_2 + 1*stim1_3 + 1*stim1_4
"

lst_fit <- sem(lst1, data = affect, meanstructure = TRUE)
fitmeasures(lst_fit)[c("chisq", "df", "pvalue", "srmr", "rmsea", "cfi", "tli")]
```

chisq	df	pvalue	srmr	rmsea	cfi	tli
4.38367002	5.00000000	0.49559718	0.01587412	0.00000000	1.00000000	1.00148570

```
summary(lst_fit, standardize = TRUE)
```

lavaan 0.6.15 ended normally after 19 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	9
Number of observations	249

Model Test User Model:



Test statistic	4.384
Degrees of freedom	5
P-value (Chi-square)	0.496

## Parameter Estimates:

Standard errors	Standard
Information	Expected
Information saturated (h1) model	Structured

## Latent Variables:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
Int =~						
stim1_1	1.000				1.519	0.785
stim1_2	1.000				1.519	0.819
stim1_3	1.000				1.519	0.799
stim1_4	1.000				1.519	0.800

## Intercepts:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stim1_1	3.137	0.123	25.598	0.000	3.137	1.622
.stim1_2	3.361	0.117	28.616	0.000	3.361	1.813
.stim1_3	3.446	0.121	28.594	0.000	3.446	1.812
.stim1_4	3.602	0.120	29.957	0.000	3.602	1.898
Int	0.000				0.000	0.000

## Variances:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stim1_1	1.432	0.161	8.902	0.000	1.432	0.383
.stim1_2	1.129	0.136	8.286	0.000	1.129	0.329
.stim1_3	1.310	0.151	8.686	0.000	1.310	0.362
.stim1_4	1.294	0.150	8.656	0.000	1.294	0.359
Int	2.306	0.236	9.772	0.000	1.000	1.000

- Das LST Modell mit einem zeitstabilen Faktor und freien Item-Intercepts über die Zeit passt sehr gut auf die Daten.
- Growth Faktor wird nicht benötigt (keine inter-individuellen Unterschiede im Wachstum), aber Mittelwerte der Stimmung steigen über die Zeit hinweg leicht an (-> Item Intercepts; bzw. mittlerer Growth))

### Zusatzaufgabe 1 LGC (optional)

Spezifizieren Sie das Latent State Modell für die Stimmung (Items `stim1` und `stim6`) (ohne indikatorspezifischem Residualfaktor) aus dem Skript der Übung 13 (SEM) aus dem Wintersemester (Code siehe Unterlagen des WS → copy pasten)

```
ls <- "
stim1 =~ 1*stim1_1 + lam*stim6_1
stim2 =~ 1*stim1_2 + lam*stim6_2
stim3 =~ 1*stim1_3 + lam*stim6_3
stim4 =~ 1*stim1_4 + lam*stim6_4
"
```

Erweitern Sie nun das Modell so, dass Sie ein lineares Growth Modell für die *latenten* Variablen `stim1` - `stim4` erstellen. Achten Sie darauf, dass Sie die Intercepts für die Items `stim1_t` auf Null fixieren und die der Items `stim6_t` über die Zeit konstant setzen. Schätzen Sie die Erwartungswerte des Latent Intercept Faktors und des Latent Slope Faktors frei.

```
lgc2 <- "
stim1 =~ 1*stim1_1 + lam*stim6_1
stim2 =~ 1*stim1_2 + lam*stim6_2
stim3 =~ 1*stim1_3 + lam*stim6_3
stim4 =~ 1*stim1_4 + lam*stim6_4

Int =~ 1*stim1 + 1*stim2 + 1*stim3 + 1*stim4
Slo =~ 0*stim1 + 1*stim2 + 2*stim3 + 3*stim4

stim1_1 ~ 0*1
stim1_2 ~ 0*1
stim1_3 ~ 0*1
stim1_4 ~ 0*1
stim6_1 ~ b*1
stim6_2 ~ b*1
stim6_3 ~ b*1
stim6_4 ~ b*1

Int ~ NA*1
Slo ~ NA*1
"

lgc_fit2 <- sem(lgc2, data = affect, meanstructure = TRUE)
fitmeasures(lgc_fit2)[c("chisq", "df", "pvalue", "srmr", "rmsea", "cfi", "tli")]
```

```

      chisq      df      pvalue      srmr      rmsea      cfi
1.071353e+02 2.500000e+01 3.839928e-12 4.052410e-02 1.148670e-01 9.385335e-01
      tli
9.311575e-01

```

```
summary(lgc_fit2, standardize = TRUE)
```

lavaan 0.6.15 ended normally after 46 iterations

```

Estimator                      ML
Optimization method            NLMINB
Number of model parameters      25
Number of equality constraints    6

Number of observations          249

```

Model Test User Model:

```

Test statistic                  107.135
Degrees of freedom              25
P-value (Chi-square)           0.000

```

Parameter Estimates:

```

Standard errors                Standard
Information                    Expected
Information saturated (h1) model Structured

```

Latent Variables:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
stim1 =~						
stim1_1	1.000				1.807	0.932
stim6_1 (lam)	0.839	0.030	28.083	0.000	1.517	0.784
stim2 =~						
stim1_2	1.000				1.714	0.922
stim6_2 (lam)	0.839	0.030	28.083	0.000	1.438	0.765
stim3 =~						
stim1_3	1.000				1.756	0.920
stim6_3 (lam)	0.839	0.030	28.083	0.000	1.473	0.777
stim4 =~						
stim1_4	1.000				1.750	0.929

stim6_4 (lam)	0.839	0.030	28.083	0.000	1.469	0.793
Int =~						
stim1	1.000				0.881	0.881
stim2	1.000				0.929	0.929
stim3	1.000				0.907	0.907
stim4	1.000				0.910	0.910
Slo =~						
stim1	0.000				0.000	0.000
stim2	1.000				0.162	0.162
stim3	2.000				0.316	0.316
stim4	3.000				0.475	0.475
Covariances:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
Int ~~						
Slo	-0.135	0.080	-1.677	0.094	-0.305	-0.305
Intercepts:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stim1_1	0.000				0.000	0.000
.stim1_2	0.000				0.000	0.000
.stim1_3	0.000				0.000	0.000
.stim1_4	0.000				0.000	0.000
.stim6_1 (b)	0.720	0.110	6.554	0.000	0.720	0.372
.stim6_2 (b)	0.720	0.110	6.554	0.000	0.720	0.383
.stim6_3 (b)	0.720	0.110	6.554	0.000	0.720	0.380
.stim6_4 (b)	0.720	0.110	6.554	0.000	0.720	0.388
Int	3.172	0.116	27.443	0.000	1.991	1.991
Slo	0.144	0.034	4.213	0.000	0.521	0.521
.stim1	0.000				0.000	0.000
.stim2	0.000				0.000	0.000
.stim3	0.000				0.000	0.000
.stim4	0.000				0.000	0.000
Variances:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stim1_1	0.495	0.146	3.384	0.001	0.495	0.132
.stim6_1	1.441	0.162	8.883	0.000	1.441	0.385
.stim1_2	0.517	0.132	3.922	0.000	0.517	0.150
.stim6_2	1.462	0.157	9.297	0.000	1.462	0.414
.stim1_3	0.556	0.141	3.943	0.000	0.556	0.153
.stim6_3	1.423	0.158	9.016	0.000	1.423	0.396
.stim1_4	0.487	0.136	3.590	0.000	0.487	0.137

.stim6_4	1.274	0.146	8.747	0.000	1.274	0.371
.stim1	0.730	0.210	3.472	0.001	0.223	0.223
.stim2	0.592	0.151	3.929	0.000	0.202	0.202
.stim3	0.776	0.165	4.698	0.000	0.252	0.252
.stim4	0.641	0.203	3.156	0.002	0.209	0.209
Int	2.537	0.311	8.164	0.000	1.000	1.000
Slo	0.077	0.037	2.051	0.040	1.000	1.000

Die Ergebnisse des Growth beziehen sich nun auf messfehlerfreie latente Variablen. Wir erhalten zudem Schätzwerte für die Messfehlervarianzen. Die mittleren Werte des latenten Intercept und Growth sowie auch ihre Varianzen sind ähnlich wie beim single-Indikator Modell (s. oben), die Varianz des random Slopes ist nun sign. Das Modell passt nicht gut auf die Daten, was sich wieder, wie im Skript des WS bereits festgestellt und ausgeführt, durch indikator-spezifische stabile Effekte erklären lässt. Wir können auch hier den indicatorspezifischen Residualfaktor für das zweite Item wieder hinzunehmen. Wir müssen darauf achten, dass dieser Faktor (ITR im Modell) nicht mit den anderen Faktoren im Modell korrelieren darf.

## Zusatzaufgabe 2 LGC (optional)

```
lgc3 <- "
stim1 =~ 1*stim1_1 + lam*stim6_1
stim2 =~ 1*stim1_2 + lam*stim6_2
stim3 =~ 1*stim1_3 + lam*stim6_3
stim4 =~ 1*stim1_4 + lam*stim6_4

Int =~ 1*stim1 + 1*stim2 + 1*stim3 + 1*stim4
Slo =~ 0*stim1 + 1*stim2 + 2*stim3 + 3*stim4

stim1_1 ~ 0*1
stim1_2 ~ 0*1
stim1_3 ~ 0*1
stim1_4 ~ 0*1
stim6_1 ~ b*1
stim6_2 ~ b*1
stim6_3 ~ b*1
stim6_4 ~ b*1

Int ~ NA*1
Slo ~ NA*1

ITR =~ 1*stim6_1 + 1*stim6_2 + 1*stim6_3 + 1*stim6_4
```

```
ITR ~~ 0*stim1 + 0*stim2 + 0*stim3 + 0*stim4 + 0*Int + 0*Slo
"

lgc_fit3 <- sem(lgc3, data = affect, meanstructure = TRUE)
fitmeasures(lgc_fit3)[c("chisq", "df", "pvalue", "srmr", "rmsea", "cfi", "tli")]
```

	chisq	df	pvalue	srmr	rmsea	cfi
	10.17622325	24.00000000	0.99378134	0.01929373	0.00000000	1.00000000
tli						
	1.01206931					